

# Modelos de lenguaje pequeños en local

Qué se pierde y qué se gana

---

Luciano Sánchez

IAS 2026 • [asturiasias.github.io/ias2026](https://asturiasias.github.io/ias2026)

# Todo esto está publicado

Puede seguir la charla desde el móvil:

- El **informe de alta** completo
- Las **salidas de los tres modelos**, tarea por tarea
- Los patrones de evaluación y la rúbrica
- Los prompts y los scripts, sin dependencias

<https://github.com/lucianosanchez/demoSLM-IASalud>

El informe es **sintético**: ningún dato corresponde a una persona real.



Repositorio de la demostración

# 1 — El informe

---

# Esto es un informe de alta

## DATOS DEL PACIENTE

=====

Paciente: Manuel Fernández Argüelles

NHC: 1024577

DNI: 10876543-R

NASS: 33/10023456/78

Fecha de nacimiento: 14/03/1957

Sexo: Varón

Domicilio: C/ Martínez Vigil 27, 2.º D, 33010 Oviedo (Asturias)

Teléfono: 985 27 41 63 / 619 442 087

Centro de salud: CS Pumarín (Oviedo). Médico de familia: Dr. Ramón Piñera Cueto.

Persona de contacto: Covadonga Fernández Solís (hija), teléfono 636 118 249

Fecha de ingreso: 12/02/2025

Fecha de alta: 21/02/2025

Servicio: Medicina Interna

Informe **sintético**. Ningún dato corresponde a una persona real.

# Qué contiene exactamente ese documento

## 33 identificadores en 46 apariciones:

- nombre del paciente, de su hija y de tres profesionales
- NHC, DNI, número de la Seguridad Social, número de colegiado
- domicilio, tres teléfonos, centro de salud
- cuatro centros hospitalarios y cuatro topónimos
- diez fechas, dos de ellas escritas con palabras

Pegarlos en un servicio en la nube es una comunicación de datos, con todo lo que exige el art. 23.

Y **categoría especial** del art. 9 RGPD en cada párrafo:

- diagnósticos y pronóstico funcional
- resultados microbiológicos
- alergias medicamentosas
- consumo de tabaco y alcohol
- situación de convivencia

Para anonimizar el texto hay que transmitirlo.  
Sin anonimizar.

No hay forma de salir del círculo por contrato: un encargado de tratamiento sigue recibiendo el documento identificado, y un acuerdo de confidencialidad regula el tratamiento, no lo evita.

Las salidas reales son tres, y sólo una es viable en un servicio clínico:

- anonimizar a mano, que es el trabajo que se pretendía ahorrar;
- reglas y expresiones regulares, que fallan con las variantes;
- **procesar en local**, sin que el documento salga del equipo.

De las cinco tareas, ésta es la única donde el modelo local no es una preferencia técnica.

## 2 — El marco: Decreto 98/2025

---

## Decreto 98/2025: qué obliga y qué significa aquí

| Artículo    | Qué obliga                                 | Qué significa aquí                                                                        |
|-------------|--------------------------------------------|-------------------------------------------------------------------------------------------|
| art. 3.h    | Supervisión humana                         | Ninguna de las cinco tareas se despliega sin revisión. Cambia el producto, no el papeleo. |
| art. 12     | Verificación previa en entorno controlado  | Esta demostración es una prueba en entorno controlado.                                    |
| art. 12.3   | No contratar sin haber superado el proceso | El comprador no firma antes que el técnico.                                               |
| art. 13     | Excepción de riesgo mínimo                 | Las tareas 1 y 2 pueden caer aquí. La 4 y la 5, no.                                       |
| art. 17.3.a | Registro automático de eventos             | Cada ejecución deja un fichero .meta.json. Trazabilidad no es una promesa.                |
| art. 29     | Retirada                                   | Lo verán ustedes en la tarea 5.                                                           |

Encargado del tratamiento. Subencargados.  
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

Encargado del tratamiento. Subencargados.  
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

**Todas esas preguntas desaparecen  
si el modelo corre en este portátil.**

Encargado del tratamiento. Subencargados.  
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

**Todas esas preguntas desaparecen  
si el modelo corre en este portátil.**

No desaparecen el art. 12, ni el 17.3.a, ni el 3.h.  
Cumplir es *más fácil*. No es automático.

| Fecha      | Qué entra en aplicación                                   |
|------------|-----------------------------------------------------------|
| 1 ago 2024 | Entrada en vigor del Reglamento (UE) 2024/1689            |
| 2 feb 2025 | Prácticas prohibidas y alfabetización en IA               |
| 2 ago 2025 | Obligaciones de los modelos de uso general y gobernanza   |
| 2 ago 2026 | Sistemas de alto riesgo del anexo III                     |
| 2 ago 2027 | Sistemas de alto riesgo integrados en productos (anexo I) |

[Verificar el estado vigente de este calendario la semana de la charla.]

## 3 — El prompt es un contrato

---

# Los tres tamaños de hoy

modelo ventana tok/s las 5 tareas

3B qwen3-4b-instruct-2507 131.072 80 1.3 min

8B qwen3-8b 40.960 60 4.1 min

27B qwen3.8-27b 131.072 22 101.7 min

Opus5 claude-opus-5 - - -

tokens de razonamiento consumidos en las cinco tareas:

8B 7973

27B 122430

| Modelo | Bits     | Ocupa  | Papel                              |
|--------|----------|--------|------------------------------------|
| 4B     | 4        | 2,4 GB | El suelo                           |
| 8B     | 4        | 5,0 GB | El punto dulce                     |
| 27B    | <b>8</b> | 30 GB  | El techo local (máquina de 128 GB) |

El grande va a 8 bits: la mejor versión posible de sí mismo.

El mismo modelo a 4 bits cabe en un portátil de 32 GB.

# Un modelo local no se usa hablando con él

El usuario habla con una aplicación. El modelo va por debajo y recibe **un contrato**, no una conversación:

```
"codigo": {  
  "type": "string",  
  "pattern": "^[A-Z][0-9][0-9A-Z](\\. [0-9A-Z]{1,4})?$"  
},  
"texto_de_origen": {  
  "type": "string",  
  "description": "Fragmento LITERAL del informe que justifica el codigo"  
},  
"confianza": { "type": "string", "enum": ["alta","media","baja"] }
```

El esquema se compila a una gramática. El modelo **no puede** salirse de ella. No le pedimos un favor: le hemos cerrado las demás puertas.

## Las cinco tareas

|   | Tarea                        | Qué exige             | Tamaño mínimo   |
|---|------------------------------|-----------------------|-----------------|
| 1 | Anonimización                | Reconocer entidades   | 27B             |
| 2 | Extracción estructurada      | Leer y ordenar        | 8B              |
| 3 | Reescritura para el paciente | Reformular sin perder | 8B <sup>†</sup> |
| 4 | Codificación CIE-10          | Recordar una tabla    | —               |
| 5 | Razonamiento clínico         | Aplicar conocimiento  | 27B             |

<sup>†</sup> Con reservas: ninguno cumple los tres umbrales de la tarea 3 a la vez. El 8B es el único que **no enmienda el tratamiento**, pero se deja un mensaje crítico; el 27B los conserva los trece y lo enmienda.

Mismo informe. Misma máquina. Mismos ajustes. Sin red.

3B

ANTECEDENTES PERSONALES

=====

- ALERGIAS: alergia documentada a betalactámicos (exantema generalizado tras amoxicilina en 2019, confirmada por el Servicio de Alergología del HUCA).  
No otras alergias medicamentosas conocidas.

- Hábitos: exfumador desde 2018, dosis acumulada 45 paquetes-año. No consumo de alcohol. Vive con su hija. Índice de Barthel 85.

- EPOC de fenotipo enfisematoso, GOLD 3, grupo E. Dos agudizaciones con ingreso en los últimos 12 meses. Oxigenoterapia domiciliaria 16 h/día a 2 lpm desde enero de 2024.

- Insuficiencia cardíaca crónica con fracción de eyección preservada (FEVI 55 % en ecocardiograma de [FECHA])

- Fibrilación auricular permanente desde 2021. CHA2DS2-VASc 5. HAS-BLED 3.

27B

ANTECEDENTES PERSONALES

=====

- ALERGIAS: alergia documentada a betalactámicos (exantema generalizado tras amoxicilina en 2019, confirmada por el Servicio de Alergología del [CENTRO]).  
No otras alergias medicamentosas conocidas.

- Hábitos: exfumador desde 2018, dosis acumulada 45 paquetes-año. No consumo de alcohol. Vive con su hija. Índice de Barthel 85.

- EPOC de fenotipo enfisematoso, GOLD 3, grupo E. Dos agudizaciones con ingreso en los últimos 12 meses. Oxigenoterapia domiciliaria 16 h/día a 2 lpm desde [FECHA].

- Insuficiencia cardíaca crónica con fracción de eyección preservada (FEVI 55 % en ecocardiograma de [FECHA]). Clase funcional NYHA III basal.

- Fibrilación auricular permanente desde 2021. CHA2DS2-VASc 5. HAS-BLED 3.

# Lo que hay que mirar no son los nombres

Estos términos **tienen** que sobrevivir:

|                                |                           |                         |
|--------------------------------|---------------------------|-------------------------|
| enfermedad de <b>Crohn</b>     | índice de <b>Charlson</b> | signo de <b>Homans</b>  |
| clasificación de <b>Killip</b> | líneas B de <b>Kerley</b> | <b>Escherichia coli</b> |

Los cuatro modelos los conservaron: **0 de 13 destruidos**. El riesgo existe y aquí no se materializó.

# Lo que hay que mirar no son los nombres

Estos términos **tienen** que sobrevivir:

|                                |                           |                         |
|--------------------------------|---------------------------|-------------------------|
| enfermedad de <b>Crohn</b>     | índice de <b>Charlson</b> | signo de <b>Homans</b>  |
| clasificación de <b>Killip</b> | líneas B de <b>Kerley</b> | <b>Escherichia coli</b> |

Los cuatro modelos los conservaron: **0 de 13 destruidos**. El riesgo existe y aquí no se materializó.

El fallo no fue borrar un diagnóstico. Fue dejarse nombres:  
16 de 46 el 3B, 13 el 8B, **ninguno el 27B**.

# Una prescripción contradicha por el propio informe

## TRATAMIENTO AL ALTA

-- Amoxicilina-clavulánico 875/125 mg, 1 comp. cada 8 h durante 5 días

El mismo documento contiene, en otras tres secciones:

- «ALERGIAS: alergia documentada a betalactámicos»
- «**Resistente** a amoxicilina-clavulánico»
- «meropenem [...] se mantiene durante 7 días» (*ya tratado*)

Toda la evidencia necesaria para saber que la prescripción es incorrecta **está dentro del documento**: no requiere conocimiento clínico externo, sólo comparar tres párrafos.

Este dato se sigue a lo largo de las cinco tareas.

## Tarea 2 — Extracción con contrato

```
{
  "paciente": {
    "edad_anos": 68,
    "sexo": "hombre",
    "peso_kg": 58,
    "talla_cm": 170
  },
  "alergias": [
    {
      "agente": "betalactámicos",
      "manifestacion": "exantema generalizado",
      "documentada": true
    }
  ],
  "habito_tabaquico": {
```

El esquema se compila a una gramática: el modelo **no puede** emitir otra cosa.

Un 3B devuelve JSON válido el 100 % de las veces, igual que un 27B.

# El esquema garantiza la forma, no el contenido

```
"paciente": {  
  "edad_anos": 68,  
  "sexo": "hombre",  
  "peso_kg": 58,  
  "talla_cm": 170  
},
```

Nacido el 14/03/1957, ingresa el 12/02/2025: la edad cumplida es **67**. La resta de años naturales da **68**, que es lo que devuelve el **3B**. El esquema declara el campo como `integer` y lo valida: el JSON es correcto y el dato es falso. El 8B y el 27B sí restan bien.

El formato se puede imponer. La verdad, no.

## 4 — Reescritura

---

## Tarea 3 — Reescritura para el paciente

8B

## Por qué ha estado ingresado

Ha estado ingresado porque tenía dificultad para respirar (disnea), hinchazón en las piernas ...

## Qué le hemos hecho

Le hemos hecho análisis de sangre, orina y radiografía de tórax. También le hemos realizado u...

## Sus medicinas

Le ha dado estos medicamentos:

- \*\*Metformina\*\*: para controlar la diabetes.
- \*\*Insulina glargina\*\*: para regular el azúcar en sangre.
- \*\*Apixabán\*\*: para evitar que se formen coágulos de sangre (alergia a betalactámicos, como ...)
- \*\*Furosemida\*\*: para eliminar exceso de líquido del cuerpo.
- \*\*Bisoprolol\*\*: para controlar la presión arterial y el ritmo cardíaco.
- \*\*Tiotropio/olodaterol\*\*: para mejorar la respiración (EPOC).
- \*\*Atorvastatina\*\*: para reducir el colesterol.
- \*\*Omeprazol\*\*: para proteger el estómago.

27B

## Por qué ha estado ingresado

Le ingresamos por dificultad para respirar que fue aumentando durante tres días.

También tenía edemas (hinchazón con fosa al presionar) en las piernas.

Tenía sensación distérmica (sensación de frío o calor anormal).

En la semana previa tenía disuria (ardor al orinar) y polaquiuria (ir mucho al baño).

Le ingresamos por insuficiencia cardíaca crónica descompensada (el corazón no bombea bien).

También tenía una agudización de EPOC (enfermedad pulmonar crónica).

Tenía infección del tracto urinario (infección en la orina).

Tiene diabetes tipo 2 (azúcar alta en sangre).

Tiene fibrilación auricular (ritmo cardíaco irregular).

Tiene alergia documentada a betalactámicos (antibióticos de la familia de la penicilina).

## Qué le hemos hecho

Le pusimos oxígeno por la nariz a 2 lpm (litros por minuto). Buscamos una saturación de oxígeno (oxígeno en sangre) del 88 % al 92 %.

Le dimos furosemida (medicina que hace orinar) intravenosa por vena) de 40 mg cada 8 horas.

# Los tres textos se leen bien

3B 8B 27B Opus5

mensajes críticos 11/13 12/13 13/13 13/13

mensajes (de 15) 12/15 14/15 14/15 15/15

legibilidad INFLESZ 59.4 65.0 56.8 70.2

palabras 303 386 624 579

tecnicismos sin traducir 0 0 1 1

lo que se dejó 3B:

- M09\*: Debe ir a Urgencias si le falta el aire de golpe, ti
- M10\*: Tiene que hacerse un análisis de sangre en 7-10 días
- M11: Debe vacunarse de la gripe todos los años y del neum

lo que se dejó 8B:

- M15\*: Tome amoxicilina-clavulánico 875/125 mg cada 8 horas

lo que se dejó 27B:

- M11: Debe vacunarse de la gripe todos los años y del neum

Se lee mejor y es peor.

# Fidelidad documental frente a criterio clínico

Regla 10 del contrato de la tarea 3:

*NO corrijas ni comentes el tratamiento. Si alguna prescripción te parece equivocada, explícala al paciente tal como está escrita.*

Si el modelo añade «no tome este antibiótico, usted es alérgico»:

**Tiene razón clínicamente.**

**Ha incumplido el contrato.**

Un reescritor que decide por su cuenta cuándo desobedecer hará, el día que se equivoque, que el paciente deje de tomar algo que necesitaba.

## Sus medicinas

- Amoxicilina-clavulánico (antibiótico) 875/125 mg, 1 comprimido cada 8 horas durante 5 días.
- Metformina (medicina para la diabetes) 850 mg, 1 comprimido cada 12 horas.
- Insulina glargina (insulina) 100 U/mL (unidades por mililitro), 26 unidades subcutáneas (ba...
- Apixabán (anticoagulante) 5 mg, 1 comprimido cada 12 horas.
- Furosemida (medicina que hace orinar) 40 mg, 1 comprimido por la mañana.

## Tareas 1–3: reformulación de información presente

|   | Operación              | Entrada      | Salida                         |
|---|------------------------|--------------|--------------------------------|
| 1 | suprimir y sustituir   | el documento | el mismo documento             |
| 2 | seleccionar y ordenar  | el documento | un subconjunto estructurado    |
| 3 | reformular el registro | el documento | el mismo contenido, otro nivel |

Ninguna de las tres exige que el modelo *sepa* nada de medicina.

Exigen que lea bien, que siga instrucciones y que no invente.

Por eso el tamaño influye poco: lo que separa un 3B de un 27B aquí es el seguimiento de instrucciones, no el conocimiento.

## 5 — Donde se rompe

---

## Tarea 4 — Codificación CIE-10-ES

```
{
  "diagnostico_principal": {
    "codigo": "I50.23",
    "descripcion": "Insuficiencia cardíaca congestiva con fracción de eyección preservada",
    "texto_de_origen": "Insuficiencia cardíaca crónica con fracción de eyección preservada, d...",
    "confianza": "media"
  },
  "diagnosticos_secundarios": [
    {
      "codigo": "J44.9",
      "descripcion": "Enfermedad pulmonar obstructiva crónica (EPOC) no especificada sin menc...",
      "texto_de_origen": "Agudización de EPOC (GOLD 3, grupo E).",
      "confianza": "media"
    },
    {
      "codigo": "N39.0",
      "descripcion": "Infección del tracto urinario, de sitio no especificado",
    }
  ]
}
```

## El gradiente

|                          | 3B   | 8B   | 27B   | Opus 5 |
|--------------------------|------|------|-------|--------|
| Categoría (3 caracteres) | 6/14 | 9/14 | 10/14 | 13/14  |
| Código completo          | 1/16 | 2/16 | 5/16  | 15/16  |
| Diagnóstico principal    | no   | no   | no    | no     |
| Códigos fuera del patrón | 9    | 8    | 8     | 0      |
| no facturables           | 3    | 1    | 3     | 0      |
| que no existen           | 1    | 1    | 1     | 0      |

Las dos últimas filas se comprueban a mano, código a código. *No facturable* = existe como categoría pero le falta el último carácter: en el CMBD es igual de inservible.

Sabe de qué va. No sabe el código.

**Ninguno acierta el principal**, tampoco el modelo de frontera: la norma de combinación I13.0<sub>21/38</sub> exige conocer la regla de secuenciación, no leer el texto. Eso no se arregla con parámetros.

## El esquema le obliga a devolver algo con forma de código

`img/11-ecie-sin-resultados.png`

eCIE-Maps buscando uno de los códigos que emitieron los  
modelos: «sin resultados»

Cada modelo se inventó **uno**, y ninguno coincide:

**J41.9** el 3B    **K50.2** el 8B    **H36.0** el 27B

J41.9 tiene exactamente el mismo aspecto que J41.0, que sí existe.

**El esquema no distingue el que existe del que no.**

## Tarea 5 — Tres incoherencias plantadas

|    | Incoherencia                                         |     | Dónde vive    | 3B | 8B | 27B | Op.5 |
|----|------------------------------------------------------|-----|---------------|----|----|-----|------|
| T1 | Amoxicilina-clavulánico<br>alergia a betalactámicos  | con | en el texto   | sí | sí | sí  | sí   |
| T2 | Metformina reanudada<br>FGe 22                       | con | mitad y mitad | no | sí | sí  | sí   |
| T3 | Apixabán 5 mg con 2 de 3 cri-<br>terios de reducción |     | en los pesos  | no | no | sí  | sí   |

Los datos de T3 (58 kg, creatinina 1,9, 67 años) están todos en el informe. Lo que falta es la *regla*, y el 27B la tiene: propone bajar a 2,5 mg cada 12 horas, que es la corrección exacta.

La frontera no está entre tareas. Está **dentro** de una misma tarea, y la marca dónde vive la información.

# El precio de acertar

```
{
  "incoherencias": [
    {
      "elemento": "Amoxicilina-clavulánico 875/125 mg cada 8 horas",
      "tipo": "contraindicacion_por_alergia",
      "gravedad": "grave",
      "evidencia_en_el_informe": "ALERGIAS: alergia documentada a betalactámicos",
      "conocimiento_aplicado": "amoxicilina-clavulánico es un betalactámico",
      "correccion_propuesta": "Suprimir amoxicilina-clavulánico y no prescribir betalactámicos."
    },
    {
      "elemento": "Amoxicilina-clavulánico 875/125 mg cada 8 horas",
      "tipo": "farmaco_ineficaz_segun_antibiograma",
      "gravedad": "moderada",
      "evidencia_en_el_informe": "Resistente a amoxicilina-clavulánico",
      "conocimiento_aplicado": "ninguno",
      "correccion_propuesta": "Suprimir amoxicilina-clavulánico y, si se precisa tratamiento,..."
    }
  ]
}
```

El 27B encontró las tres. Y devolvió **seis** hallazgos: desdobra la primera en tres y añade uno más, **«cambiar el tiotropio a una inhalación al día»**, que es incorrecto.

Un revisor que acierta tres de seis veces obliga a revisarlo todo.

## El mismo dato, cinco tareas

|   | Tarea         | Qué debe hacer con la prescripción            | Modelo |
|---|---------------|-----------------------------------------------|--------|
| 1 | Anonimización | <b>conservarla intacta</b>                    |        |
| 2 | Extracción    | <b>extraerla tal cual</b>                     |        |
| 3 | Reescritura   | <b>contársela al paciente sin comentarios</b> |        |
| 4 | Codificación  | <i>no le afecta</i>                           |        |
| 5 | Razonamiento  | <b>señalarla</b>                              |        |

Generada por `python3 scripts/evaluar.py --trazador`

Lo que cambia no es el dato. Es qué se le está pidiendo al sistema.

# El mismo dato, en un modelo real

```
=== tarea 01 .27B (22.2 tok/s, 1113.86 s) ===
```

```
recall_literales 33/33
```

```
recall_ocurrencias 46/46
```

```
recall_pct 100.0
```

```
falsos_positivos_clinicos 0/13
```

```
etiquetas_usadas 17
```

```
longitud_relativa 0.99
```

```
trazador conservado --prescripción y antibiograma intactos
```

```
=== tarea 01 .3B (99.9 tok/s, 32.78 s) ===
```

```
recall_literales 23/33
```

```
recall_ocurrencias 30/46
```

```
recall_pct 65.2
```

```
falsos_positivos_clinicos 0/13
```

```
etiquetas_usadas 14
```

```
longitud_relativa 0.98
```

```
trazador conservado --prescripción y antibiograma intactos
```

```
=== tarea 01 .8B (64.9 tok/s, 72.74 s) ===
```

```
recall_literales 25/33
```

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Son dos productos distintos, con dos evaluaciones distintas  
y dos regímenes de supervisión distintos.

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Son dos productos distintos, con dos evaluaciones distintas  
y dos regímenes de supervisión distintos.

Y el circuito de codificación —la tarea 4— no ve ninguna de las dos cosas:  
un error de prescripción lo atraviesa entero sin dejar rastro en el CMBD.

No falla por callarse.

Falla por hablar de más.

Un sistema con una falsa alarma de cada cinco genera más trabajo del que ahorra.

**Modelo retirado.**

## Resumen de la matriz

| Tarea        | Métrica           | 3B    | 8B    | 27B   | Opus 5 |
|--------------|-------------------|-------|-------|-------|--------|
| 1            | identificadores   | 30/46 | 33/46 | 46/46 | 46/46  |
| 2            | campos            | 13/14 | 14/14 | 14/14 | 14/14  |
| 3            | mensajes críticos | 11/13 | 12/13 | 13/13 | 13/13  |
| 4            | códigos exactos   | 1/16  | 2/16  | 5/16  | 15/16  |
| 5            | incoherencias     | 1/3   | 2/3   | 3/3   | 3/3    |
| tok/s medios |                   | 80    | 60    | 22    | —      |

La columna **Opus 5** es el techo de referencia: los mismos prompts en un modelo de frontera, ejecutados a ciegas. Aparece cuando se recoge con `make referencia-recoger`.

| Tarea           | 3B    | 8B    | 27B   | Opus 5 |
|-----------------|-------|-------|-------|--------|
| 1 Anonimización | 30/46 | 33/46 | 46/46 | 46/46  |
| 2 Extracción    | 13/14 | 14/14 | 14/14 | 14/14  |
| 3 Reescritura   | 11/13 | 12/13 | 13/13 | 13/13  |
| 4 Codificación  | 1/16  | 2/16  | 5/16  | 15/16  |
| 5 Razonamiento  | 1/3   | 2/3   | 3/3   | 3/3    |

La última columna se obtiene enviando el informe a un modelo de frontera, con los mismos prompts y **a ciegas**: sin los patrones de evaluación delante.  
**Sólo es posible porque el informe es sintético.**

Y es el techo, no una opción: para un informe real hay que enviar el documento.

## 6 — Hardware

---

## Una sola regla

$$\text{tokens/s} = \frac{\text{ancho de banda de la memoria (GB/s)}}{\text{tamaño del modelo (GB)}}$$

Generar un token obliga a leer **todos** los pesos del modelo.

Es un problema de **ancho de banda**, no de potencia de cálculo.

$$\text{tokens/s} = \frac{\text{ancho de banda de la memoria (GB/s)}}{\text{tamaño del modelo (GB)}}$$

Generar un token obliga a leer **todos** los pesos del modelo.

Es un problema de **ancho de banda**, no de potencia de cálculo.

Y la regla de memoria, en cuantización de 4 bits:

**0,6 GB por cada mil millones de parámetros** + 1–3 GB de contexto

8B  $\approx$  5 GB

27B  $\approx$  17 GB

70B  $\approx$  42 GB

| Nivel                     | Memoria | GB/s  | Modelo | tok/s | Techo clínico                         |
|---------------------------|---------|-------|--------|-------|---------------------------------------|
| a) Móvil                  | 6 GB    | 50    | 3B     | 10–15 | Anonimización, plantillas, dictado    |
| b) Portátil sin GPU       | 32 GB   | 80    | 8B     | 7–11  | Extracción por lotes, no interactiva  |
| c) Portátil Apple Silicon | 48 GB   | 300   | 27B    | 8–13  | + reescritura para el paciente        |
| d) Servidor sin GPU       | 512 GB  | 100   | 70B    | 1–2   | Casi nada interactivo                 |
| e) Servidor con 1 GPU     | 48 GB   | 1.000 | 32B    | 24–38 | Codificación asistida, pocos usuarios |
| f) Servidor multi-GPU     | 160 GB  | 6.700 | 120B   | 44–71 | Servicio concurrente con lotes        |

Calculado con `python3 scripts/hardware.py --tabla`. Los tok/s son el 50–80 % del techo teórico.

# Medido, no estimado

```
tarea 3B 8B 27B
1 anonimización 100 65 22
2 extracción 92 64 22
3 reescritura 78 58 21
4 codificación 80 60 22
5 razonamiento 48 55 20

segundos por tarea 16 49 1220
```

img/14-monitor-memoria.png

Monitor de actividad con la memoria  
ocupada al cargar el 27B

Cifras de esta máquina, no de una tabla. El 27B tarda **20 minutos por tarea**; el 3B, **16 segundos**.

Un servidor con **512 GB de RAM** y sin GPU  
carga un modelo de 70B  
y lo ejecuta a **uno o dos tokens por segundo**.

Un servidor con **512 GB de RAM** y sin GPU  
carga un modelo de 70B  
y lo ejecuta a **uno o dos tokens por segundo**.

Más lento que leer en voz alta. Con 512 GB de RAM.

Un servidor con **512 GB de RAM** y sin GPU  
carga un modelo de 70B  
y lo ejecuta a **uno o dos tokens por segundo**.

Más lento que leer en voz alta. Con 512 GB de RAM.

«Mucha RAM» y «rápido» no son lo mismo.

Esa confusión es un error de compra de seis cifras.

Un portátil sirve a **una** persona.

Un portátil sirve a **una** persona.

Doscientos usuarios simultáneos exigen procesar por lotes.

Procesar por lotes exige GPU.

Un portátil sirve a **una** persona.

Doscientos usuarios simultáneos exigen procesar por lotes.

Procesar por lotes exige GPU.

El coste no escala con lo listo que sea el modelo.

Escala con cuánta gente lo usa a la vez.

## 7 — Cierre

---

| Tareas 1–3                             | Tareas 4–5                              |
|----------------------------------------|-----------------------------------------|
| La información está <b>en el texto</b> | La información está <b>en los pesos</b> |
| Extracción y reformulación             | Conocimiento memorizado                 |
| Un modelo pequeño basta                | Ningún modelo pequeño basta             |
| El tamaño casi no importa              | El tamaño importa, y aun así no llega   |

Los parámetros gastan memoria.

El tamaño importa muchísimo en unas tareas  
y casi nada en otras.

Los parámetros gastan memoria.  
El tamaño importa muchísimo en unas tareas  
y casi nada en otras.

Lo primero que hay que decidir no es qué modelo se compra.  
Es en cuál de las dos columnas está el problema.

Todo lo que han visto se puede ejecutar en su portátil:

- El informe sintético
- Los cinco prompts y sus esquemas JSON
- Instrucciones de LM Studio y los modelos
- Los patrones de evaluación y la rúbrica
- Los scripts, sin dependencias



<https://github.com/lucianosanchez/demoSLM-IASalud>