

Modelos de lenguaje pequeños en local

Qué se pierde y qué se gana

Luciano Sánchez

IAS 2026 • asturiasias.github.io/ias2026

Todo esto está publicado

Puede seguir la charla desde el móvil:

- El **informe de alta** completo
- Las **salidas de los tres modelos**, tarea por tarea
- Los patrones de evaluación y la rúbrica
- Los prompts y los scripts, sin dependencias

<https://github.com/lucianosanchez/demoSLM-IASalud>

El informe es **sintético**: ningún dato corresponde a una persona real.



Repositorio de la demostración

1 — El informe

Esto es un informe de alta

DATOS DEL PACIENTE

=====

Paciente: Manuel Fernández Argüelles

NHC: 1024577

DNI: 10876543-R

NASS: 33/10023456/78

Fecha de nacimiento: 14/03/1957

Sexo: Varón

Domicilio: C/ Martínez Vigil 27, 2.º D, 33010 Oviedo (Asturias)

Teléfono: 985 27 41 63 / 619 442 087

Centro de salud: CS Pumarín (Oviedo). Médico de familia: Dr. Ramón Piñera Cueto.

Persona de contacto: Covadonga Fernández Solís (hija), teléfono 636 118 249

Fecha de ingreso: 12/02/2025

Fecha de alta: 21/02/2025

Servicio: Medicina Interna

Informe **sintético**. Ningún dato corresponde a una persona real.

Qué contiene exactamente ese documento

33 identificadores en 46 apariciones:

- nombre del paciente, de su hija y de tres profesionales
- NHC, DNI, número de la Seguridad Social, número de colegiado
- domicilio, tres teléfonos, centro de salud
- cuatro centros hospitalarios y cuatro topónimos
- diez fechas, dos de ellas escritas con palabras

Pegarlos en un servicio en la nube es una comunicación de datos, con todo lo que exige el art. 23.

Y **categoría especial** del art. 9 RGPD en cada párrafo:

- diagnósticos y pronóstico funcional
- resultados microbiológicos
- alergias medicamentosas
- consumo de tabaco y alcohol
- situación de convivencia

Para anonimizar el texto hay que transmitirlo.
Sin anonimizar.

No hay forma de salir del círculo por contrato: un encargado de tratamiento sigue recibiendo el documento identificado, y un acuerdo de confidencialidad regula el tratamiento, no lo evita.

Las salidas reales son tres, y sólo una es viable en un servicio clínico:

- anonimizar a mano, que es el trabajo que se pretendía ahorrar;
- reglas y expresiones regulares, que fallan con las variantes;
- **procesar en local**, sin que el documento salga del equipo.

De las cinco tareas, ésta es la única donde el modelo local no es una preferencia técnica.

2 — El marco: Decreto 98/2025

Decreto 98/2025: qué obliga y qué significa aquí

Artículo	Qué obliga	Qué significa aquí
art. 3.h	Supervisión humana	Ninguna de las cinco tareas se despliega sin revisión. Cambia el producto, no el papeleo.
art. 12	Verificación previa en entorno controlado	Esta demostración es una prueba en entorno controlado.
art. 12.3	No contratar sin haber superado el proceso	El comprador no firma antes que el técnico.
art. 13	Excepción de riesgo mínimo	Las tareas 1 y 2 pueden caer aquí. La 4 y la 5, no.
art. 17.3.a	Registro automático de eventos	Cada ejecución deja un fichero .meta.json. Trazabilidad no es una promesa.
art. 29	Retirada	Lo verán ustedes en la tarea 5.

Encargado del tratamiento. Subencargados.
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

Encargado del tratamiento. Subencargados.
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

**Todas esas preguntas desaparecen
si el modelo corre en este portátil.**

Encargado del tratamiento. Subencargados.
Ubicación de los datos. Transferencias internacionales. Confidencialidad.

**Todas esas preguntas desaparecen
si el modelo corre en este portátil.**

No desaparecen el art. 12, ni el 17.3.a, ni el 3.h.
Cumplir es *más fácil*. No es automático.

Fecha	Qué entra en aplicación
1 ago 2024	Entrada en vigor del Reglamento (UE) 2024/1689
2 feb 2025	Prácticas prohibidas y alfabetización en IA
2 ago 2025	Obligaciones de los modelos de uso general y gobernanza
2 ago 2026	Sistemas de alto riesgo del anexo III
2 ago 2027	Sistemas de alto riesgo integrados en productos (anexo I)

[Verificar el estado vigente de este calendario la semana de la charla.]

3 — El prompt es un contrato

Los tres tamaños de hoy

```
modelo ventana tok/s las 5 tareas
3B qwen3-4b-instruct-2507 131.072 80 1.3 min
8B qwen3-8b 40.960 60 4.1 min
27B qwen3.8-27b 131.072 22 101.7 min
Opus5 claude-opus-5 - - -
```

```
tokens de razonamiento consumidos en las cinco tareas:
8B 7973
27B 122430
```

Modelo	Bits	Ocupa	Papel
4B	4	2,4 GB	El suelo
8B	4	5,0 GB	El punto dulce
27B	8	30 GB	El techo local (máquina de 128 GB)

El grande va a 8 bits: la mejor versión posible de sí mismo.

El mismo modelo a 4 bits cabe en un portátil de 32 GB.

Un modelo local no se usa hablando con él

El usuario habla con una aplicación. El modelo va por debajo y recibe **un contrato**, no una conversación:

```
"codigo": {  
  "type": "string",  
  "pattern": "^[A-Z][0-9][0-9A-Z](\\. [0-9A-Z]{1,4})?$"  
},  
"texto_de_origen": {  
  "type": "string",  
  "description": "Fragmento LITERAL del informe que justifica el codigo"  
},  
"confianza": { "type": "string", "enum": ["alta","media","baja"] }
```

El esquema se compila a una gramática. El modelo **no puede** salirse de ella. No le pedimos un favor: le hemos cerrado las demás puertas.

Las cinco tareas

	Tarea	Qué exige	Tamaño mínimo
1	Anonimización	Reconocer entidades	27B
2	Extracción estructurada	Leer y ordenar	8B
3	Reescritura para el paciente	Reformular sin perder	8B [†]
4	Codificación CIE-10	Recordar una tabla	—
5	Razonamiento clínico	Aplicar conocimiento	27B

[†] Con reservas: ninguno cumple los tres umbrales de la tarea 3 a la vez. El 8B es el único que **no enmienda el tratamiento**, pero se deja un mensaje crítico; el 27B los conserva los trece y lo enmienda.

Mismo informe. Misma máquina. Mismos ajustes. Sin red.

3B

ANTECEDENTES PERSONALES

=====

- ALERGIAS: alergia documentada a betalactámicos (exantema generalizado tras amoxicilina en 2019, confirmada por el Servicio de Alergología del HUCA).
No otras alergias medicamentosas conocidas.

- Hábitos: exfumador desde 2018, dosis acumulada 45 paquetes-año. No consumo de alcohol. Vive con su hija. Índice de Barthel 85.

- EPOC de fenotipo enfisematoso, GOLD 3, grupo E. Dos agudizaciones con ingreso en los últimos 12 meses. Oxigenoterapia domiciliaria 16 h/día a 2 lpm desde enero de 2024.

- Insuficiencia cardíaca crónica con fracción de eyección preservada (FEVI 55 % en ecocardiograma de [FECHA])

- Fibrilación auricular permanente desde 2021. CHA2DS2-VASc 5. HAS-BLED 3.

27B

ANTECEDENTES PERSONALES

=====

- ALERGIAS: alergia documentada a betalactámicos (exantema generalizado tras amoxicilina en 2019, confirmada por el Servicio de Alergología del [CENTRO]).
No otras alergias medicamentosas conocidas.

- Hábitos: exfumador desde 2018, dosis acumulada 45 paquetes-año. No consumo de alcohol. Vive con su hija. Índice de Barthel 85.

- EPOC de fenotipo enfisematoso, GOLD 3, grupo E. Dos agudizaciones con ingreso en los últimos 12 meses. Oxigenoterapia domiciliaria 16 h/día a 2 lpm desde [FECHA].

- Insuficiencia cardíaca crónica con fracción de eyección preservada (FEVI 55 % en ecocardiograma de [FECHA]). Clase funcional NYHA III basal.

- Fibrilación auricular permanente desde 2021. CHA2DS2-VASc 5. HAS-BLED 3.

Lo que hay que mirar no son los nombres

Estos términos **tienen** que sobrevivir:

enfermedad de Crohn	índice de Charlson	signo de Homans
clasificación de Killip	líneas B de Kerley	Escherichia coli

Los cuatro modelos los conservaron: **0 de 13 destruidos**. El riesgo existe y aquí no se materializó.

Lo que hay que mirar no son los nombres

Estos términos **tienen** que sobrevivir:

enfermedad de Crohn	índice de Charlson	signo de Homans
clasificación de Killip	líneas B de Kerley	Escherichia coli

Los cuatro modelos los conservaron: **0 de 13 destruidos**. El riesgo existe y aquí no se materializó.

El fallo no fue borrar un diagnóstico. Fue dejarse nombres:
16 de 46 el 3B, 13 el 8B, **ninguno el 27B**.

Una prescripción contradicha por el propio informe

TRATAMIENTO AL ALTA

-- Amoxicilina-clavulánico 875/125 mg, 1 comp. cada 8 h durante 5 días

El mismo documento contiene, en otras tres secciones:

- «ALERGIAS: alergia documentada a betalactámicos»
- «**Resistente** a amoxicilina-clavulánico»
- «meropenem [...] se mantiene durante 7 días» (*ya tratado*)

Toda la evidencia necesaria para saber que la prescripción es incorrecta **está dentro del documento**: no requiere conocimiento clínico externo, sólo comparar tres párrafos.

Este dato se sigue a lo largo de las cinco tareas.

Tarea 2 — Extracción con contrato

```
{
  "paciente": {
    "edad_anos": 68,
    "sexo": "hombre",
    "peso_kg": 58,
    "talla_cm": 170
  },
  "alergias": [
    {
      "agente": "betalactámicos",
      "manifestacion": "exantema generalizado",
      "documentada": true
    }
  ],
  "habito_tabaquico": {
```

El esquema se compila a una gramática: el modelo **no puede** emitir otra cosa.

Un 3B devuelve JSON válido el 100 % de las veces, igual que un 27B.

El esquema garantiza la forma, no el contenido

```
"paciente": {  
  "edad_anos": 68,  
  "sexo": "hombre",  
  "peso_kg": 58,  
  "talla_cm": 170  
},
```

Nacido el 14/03/1957, ingresa el 12/02/2025: la edad cumplida es **67**. La resta de años naturales da **68**, que es lo que devuelve el **3B**. El esquema declara el campo como `integer` y lo valida: el JSON es correcto y el dato es falso. El 8B y el 27B sí restan bien.

El formato se puede imponer. La verdad, no.

4 — Reescritura

Tarea 3 — Reescritura para el paciente

8B

Por qué ha estado ingresado

Ha estado ingresado porque tenía dificultad para respirar (disnea), hinchazón en las piernas ...

Qué le hemos hecho

Le hemos hecho análisis de sangre, orina y radiografía de tórax. También le hemos realizado u...

Sus medicinas

Le ha dado estos medicamentos:

- **Metformina**: para controlar la diabetes.
- **Insulina glargina**: para regular el azúcar en sangre.
- **Apixabán**: para evitar que se formen coágulos de sangre (alergia a betalactámicos, como ...)
- **Furosemida**: para eliminar exceso de líquido del cuerpo.
- **Bisoprolol**: para controlar la presión arterial y el ritmo cardíaco.
- **Tiotropio/olodaterol**: para mejorar la respiración (EPOC).
- **Atorvastatina**: para reducir el colesterol.
- **Omeprazol**: para proteger el estómago.

27B

Por qué ha estado ingresado

Le ingresamos por dificultad para respirar que fue aumentando durante tres días.

También tenía edemas (hinchazón con fosa al presionar) en las piernas.

Tenía sensación distérmica (sensación de frío o calor anormal).

En la semana previa tenía disuria (ardor al orinar) y polaquiuria (ir mucho al baño).

Le ingresamos por insuficiencia cardíaca crónica descompensada (el corazón no bombea bien).

También tenía una agudización de EPOC (enfermedad pulmonar crónica).

Tenía infección del tracto urinario (infección en la orina).

Tiene diabetes tipo 2 (azúcar alta en sangre).

Tiene fibrilación auricular (ritmo cardíaco irregular).

Tiene alergia documentada a betalactámicos (antibióticos de la familia de la penicilina).

Qué le hemos hecho

Le pusimos oxígeno por la nariz a 2 lpm (litros por minuto). Buscamos una saturación de oxígeno (oxígeno en sangre) del 88 % al 92 %.

Le dimos furosemida (medicina que hace orinar) intravenosa por vena) de 40 mg cada 8 horas.

Los tres textos se leen bien

3B 8B 27B Opus5

mensajes críticos 11/13 12/13 13/13 13/13

mensajes (de 15) 12/15 14/15 14/15 15/15

legibilidad INFLESZ 59.4 65.0 56.8 70.2

palabras 303 386 624 579

tecnicismos sin traducir 0 0 1 1

lo que se dejó 3B:

- M09*: Debe ir a Urgencias si le falta el aire de golpe, ti
- M10*: Tiene que hacerse un análisis de sangre en 7-10 días
- M11: Debe vacunarse de la gripe todos los años y del neum

lo que se dejó 8B:

- M15*: Tome amoxicilina-clavulánico 875/125 mg cada 8 horas

lo que se dejó 27B:

- M11: Debe vacunarse de la gripe todos los años y del neum

Se lee mejor y es peor.

Fidelidad documental frente a criterio clínico

Regla 10 del contrato de la tarea 3:

NO corrijas ni comentes el tratamiento. Si alguna prescripción te parece equivocada, explícala al paciente tal como está escrita.

Si el modelo añade «no tome este antibiótico, usted es alérgico»:

Tiene razón clínicamente.

Ha incumplido el contrato.

Un reescritor que decide por su cuenta cuándo desobedecer hará, el día que se equivoque, que el paciente deje de tomar algo que necesitaba.

Sus medicinas

- Amoxicilina-clavulánico (antibiótico) 875/125 mg, 1 comprimido cada 8 horas durante 5 días.
- Metformina (medicina para la diabetes) 850 mg, 1 comprimido cada 12 horas.
- Insulina glargina (insulina) 100 U/mL (unidades por mililitro), 26 unidades subcutáneas (ba...
- Apixabán (anticoagulante) 5 mg, 1 comprimido cada 12 horas.
- Furosemida (medicina que hace orinar) 40 mg, 1 comprimido por la mañana.

Tareas 1–3: reformulación de información presente

	Operación	Entrada	Salida
1	suprimir y sustituir	el documento	el mismo documento
2	seleccionar y ordenar	el documento	un subconjunto estructurado
3	reformular el registro	el documento	el mismo contenido, otro nivel

Ninguna de las tres exige que el modelo *sepa* nada de medicina.

Exigen que lea bien, que siga instrucciones y que no invente.

Por eso el tamaño influye poco: lo que separa un 3B de un 27B aquí es el seguimiento de instrucciones, no el conocimiento.

5 — Donde se rompe

Tarea 4 — Codificación CIE-10-ES

```
{
  "diagnostico_principal": {
    "codigo": "I50.23",
    "descripcion": "Insuficiencia cardíaca congestiva con fracción de eyección preservada",
    "texto_de_origen": "Insuficiencia cardíaca crónica con fracción de eyección preservada, d...",
    "confianza": "media"
  },
  "diagnosticos_secundarios": [
    {
      "codigo": "J44.9",
      "descripcion": "Enfermedad pulmonar obstructiva crónica (EPOC) no especificada sin menc...",
      "texto_de_origen": "Agudización de EPOC (GOLD 3, grupo E).",
      "confianza": "media"
    },
    {
      "codigo": "N39.0",
      "descripcion": "Infección del tracto urinario, de sitio no especificado",

```

El gradiente

	3B	8B	27B	Opus 5
Categoría (3 caracteres)	6/14	9/14	10/14	13/14
Código completo	1/16	2/16	5/16	15/16
Diagnóstico principal	no	no	no	no
Códigos fuera del patrón	9	8	8	0
no facturables	3	1	3	0
que no existen	1	1	1	0

Los 22 códigos fuera del patrón, comprobados uno a uno. *No facturable* = existe como categoría pero le falta el último carácter: en el CMBD es igual de inservible.

Sabe de qué va. No sabe el código.

Ninguno acierta el principal, tampoco el modelo de frontera: la norma de combinación I13.0_{21/38} exige conocer la regla de secuenciación, no leer el texto. Eso no se arregla con parámetros.

El esquema le obliga a devolver algo con forma de código

img/11-ecie-sin-resultados.png

eCIE-Maps buscando J41.9: «sin
resultados»

Cada modelo se inventó **uno**, y ninguno
coincide:

J41.9 el 3B

K50.2 el 8B

H36.0 el 27B

NO EXISTEN. El modelo se los inventó:

H36.0 27B excluido en CIE-10-ES: la retinopatía diabética va e

J41.9 3B la categoría J41 sólo tiene .0, .1 y .8

K50.2 8B la categoría K50 sólo tiene .0, .1, .8 y .9

NO SON FACTURABLES. Les falta el último carácter:

B96.2 27B categoría; exige 5.º carácter (B96.20/.21/.29)

E11.31 27B exige 5.º carácter (E11.311/E11.319)

F17.9 3B la serie facturable es F17.2xx

I48.2 27B exige 5.º carácter (I48.20/I48.21)

I48.9 3B exige 5.º carácter (I48.91/I48.92)

J96.0 8B exige 5.º carácter (J96.00/.01/.02)

K50.9 3B exige 5.º carácter (K50.90...)

Y otros 12 que existen y son válidos, pero no describen
a este paciente (I10 en vez de I13.0, J44.9 en vez de J44.1,
N18.5 en vez de N18.4...). La lista entera, con el porqué de
cada uno, en [evaluacion/verificacion-ciel0.md](#)

J41.9 tiene el mismo aspecto que J41.0, que sí existe. **El esquema no distingue uno del otro.**

Tarea 5 — Tres incoherencias plantadas

	Incoherencia		Dónde vive	3B	8B	27B	Op.5
T1	Amoxicilina-clavulánico alergia a betalactámicos	con	en el texto	sí	sí	sí	sí
T2	Metformina reanudada FGe 22	con	mitad y mitad	no	sí	sí	sí
T3	Apixabán 5 mg con 2 de 3 cri- terios de reducción		en los pesos	no	no	sí	sí

Los datos de T3 (58 kg, creatinina 1,9, 67 años) están todos en el informe. Lo que falta es la *regla*, y el 27B la tiene: propone bajar a 2,5 mg cada 12 horas, que es la corrección exacta.

La frontera no está entre tareas. Está **dentro** de una misma tarea, y la marca dónde vive la información.

El precio de acertar

```
{
  "incoherencias": [
    {
      "elemento": "Amoxicilina-clavulánico 875/125 mg cada 8 horas",
      "tipo": "contraindicacion_por_alergia",
      "gravedad": "grave",
      "evidencia_en_el_informe": "ALERGIAS: alergia documentada a betalactámicos",
      "conocimiento_aplicado": "amoxicilina-clavulánico es un betalactámico",
      "correccion_propuesta": "Suprimir amoxicilina-clavulánico y no prescribir betalactámicos."
    },
    {
      "elemento": "Amoxicilina-clavulánico 875/125 mg cada 8 horas",
      "tipo": "farmaco_ineficaz_segun_antibiograma",
      "gravedad": "moderada",
      "evidencia_en_el_informe": "Resistente a amoxicilina-clavulánico",
      "conocimiento_aplicado": "ninguno",
      "correccion_propuesta": "Suprimir amoxicilina-clavulánico y, si se precisa tratamiento,..."
    }
  ]
}
```

El 27B encontró las tres. Y devolvió **seis** hallazgos: desdobra la primera en tres y añade uno más, **«cambiar el tiotropio a una inhalación al día»**, que es incorrecto.

Un revisor que acierta tres de seis veces obliga a revisarlo todo.

El mismo dato, cinco tareas

	Tarea	Qué debe hacer con la prescripción	Modelo
1	Anonimización	conservarla intacta	
2	Extracción	extraerla tal cual	
3	Reescritura	contársela al paciente sin comentarios	
4	Codificación	<i>no le afecta</i>	
5	Razonamiento	señalarla	

Generada por `python3 scripts/evaluar.py --trazador`

Lo que cambia no es el dato. Es qué se le está pidiendo al sistema.

El mismo dato, en un modelo real

```
=== tarea 01 .27B (22.2 tok/s, 1113.86 s) ===
```

```
recall_literales 33/33
```

```
recall_ocurrencias 46/46
```

```
recall_pct 100.0
```

```
falsos_positivos_clinicos 0/13
```

```
etiquetas_usadas 17
```

```
longitud_relativa 0.99
```

```
trazador conservado --prescripción y antibiograma intactos
```

```
=== tarea 01 .3B (99.9 tok/s, 32.78 s) ===
```

```
recall_literales 23/33
```

```
recall_ocurrencias 30/46
```

```
recall_pct 65.2
```

```
falsos_positivos_clinicos 0/13
```

```
etiquetas_usadas 14
```

```
longitud_relativa 0.98
```

```
trazador conservado --prescripción y antibiograma intactos
```

```
=== tarea 01 .8B (64.9 tok/s, 72.74 s) ===
```

```
recall_literales 25/33
```

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Son dos productos distintos, con dos evaluaciones distintas
y dos regímenes de supervisión distintos.

Las tareas 1–3 miden **fidelidad documental**.

La tarea 5 mide **validación clínica**.

Son dos productos distintos, con dos evaluaciones distintas
y dos regímenes de supervisión distintos.

Y el circuito de codificación —la tarea 4— no ve ninguna de las dos cosas:
un error de prescripción lo atraviesa entero sin dejar rastro en el CMBD.

No falla por callarse.

Falla por hablar de más.

Un sistema con una falsa alarma de cada cinco genera más trabajo del que ahorra.

Modelo retirado.

Resumen de la matriz

Tarea	Métrica	3B	8B	27B	Opus 5
1	identificadores	30/46	33/46	46/46	46/46
2	campos	13/14	14/14	14/14	14/14
3	mensajes críticos	11/13	12/13	13/13	13/13
4	códigos exactos	1/16	2/16	5/16	15/16
5	incoherencias	1/3	2/3	3/3	3/3
tok/s medios		80	60	22	—

La columna **Opus 5** es el techo de referencia: los mismos prompts en un modelo de frontera, ejecutados a ciegas. Aparece cuando se recoge con `make referencia-recoger`.

Tarea	3B	8B	27B	Opus 5
1 Anonimización	30/46	33/46	46/46	46/46
2 Extracción	13/14	14/14	14/14	14/14
3 Reescritura	11/13	12/13	13/13	13/13
4 Codificación	1/16	2/16	5/16	15/16
5 Razonamiento	1/3	2/3	3/3	3/3

La última columna se obtiene enviando el informe a un modelo de frontera, con los mismos prompts y **a ciegas**: sin los patrones de evaluación delante.
Sólo es posible porque el informe es sintético.

Y es el techo, no una opción: para un informe real hay que enviar el documento.

6 — Hardware

Una sola regla

$$\text{tokens/s} = \frac{\text{ancho de banda de la memoria (GB/s)}}{\text{tamaño del modelo (GB)}}$$

Generar un token obliga a leer **todos** los pesos del modelo.

Es un problema de **ancho de banda**, no de potencia de cálculo.

$$\text{tokens/s} = \frac{\text{ancho de banda de la memoria (GB/s)}}{\text{tamaño del modelo (GB)}}$$

Generar un token obliga a leer **todos** los pesos del modelo.

Es un problema de **ancho de banda**, no de potencia de cálculo.

Y la regla de memoria, en cuantización de 4 bits:

0,6 GB por cada mil millones de parámetros + 1–3 GB de contexto

8B $\approx$ 5 GB

27B $\approx$ 17 GB

70B $\approx$ 42 GB

Nivel	Memoria	GB/s	Modelo	tok/s	Techo clínico
a) Móvil	6 GB	50	3B	10–15	Anonimización, plantillas, dictado
b) Portátil sin GPU	32 GB	80	8B	7–11	Extracción por lotes, no interactiva
c) Portátil Apple Silicon	48 GB	300	27B	8–13	+ reescritura para el paciente
d) Servidor sin GPU	512 GB	100	70B	1–2	Casi nada interactivo
e) Servidor con 1 GPU	48 GB	1.000	32B	24–38	Codificación asistida, pocos usuarios
f) Servidor multi-GPU	160 GB	6.700	120B	44–71	Servicio concurrente con lotes

Calculado con `python3 scripts/hardware.py --tabla`. Los tok/s son el 50–80 % del techo teórico.

Medido, no estimado

```
tarea 3B 8B 27B
1 anonimización 100 65 22
2 extracción 92 64 22
3 reescritura 78 58 21
4 codificación 80 60 22
5 razonamiento 48 55 20

segundos por tarea 16 49 1220
```

img/14-monitor-memoria.png

Monitor de actividad con la memoria
ocupada al cargar el 27B

Cifras de esta máquina, no de una tabla. El 27B tarda **20 minutos por tarea**; el 3B, **16 segundos**.

Un servidor con **512 GB de RAM** y sin GPU
carga un modelo de 70B
y lo ejecuta a **uno o dos tokens por segundo**.

Un servidor con **512 GB de RAM** y sin GPU
carga un modelo de 70B
y lo ejecuta a **uno o dos tokens por segundo**.

Más lento que leer en voz alta. Con 512 GB de RAM.

Un servidor con **512 GB de RAM** y sin GPU
carga un modelo de 70B
y lo ejecuta a **uno o dos tokens por segundo**.

Más lento que leer en voz alta. Con 512 GB de RAM.

«Mucha RAM» y «rápido» no son lo mismo.

Esa confusión es un error de compra de seis cifras.

Un portátil sirve a **una** persona.

Un portátil sirve a **una** persona.

Doscientos usuarios simultáneos exigen procesar por lotes.

Procesar por lotes exige GPU.

Un portátil sirve a **una** persona.

Doscientos usuarios simultáneos exigen procesar por lotes.

Procesar por lotes exige GPU.

El coste no escala con lo listo que sea el modelo.

Escala con cuánta gente lo usa a la vez.

7 — Cierre

Tareas 1–3	Tareas 4–5
La información está en el texto	La información está en los pesos
Extracción y reformulación	Conocimiento memorizado
Un modelo pequeño basta	Ningún modelo pequeño basta
El tamaño casi no importa	El tamaño importa, y aun así no llega

Los parámetros gastan memoria.

El tamaño importa muchísimo en unas tareas
y casi nada en otras.

Los parámetros gastan memoria.
El tamaño importa muchísimo en unas tareas
y casi nada en otras.

Lo primero que hay que decidir no es qué modelo se compra.
Es en cuál de las dos columnas está el problema.

Todo lo que han visto se puede ejecutar en su portátil:

- El informe sintético
- Los cinco prompts y sus esquemas JSON
- Instrucciones de LM Studio y los modelos
- Los patrones de evaluación y la rúbrica
- Los scripts, sin dependencias



<https://github.com/lucianosanchez/demoSLM-IASalud>